
IMPLEMENTASI YOLOV8 UNTUK DETEKSI OBJEK CACAT FISIK PADA CITRA BIJI KOPI ARABIKA (IMPLEMENTATION OF YOLOV8 FOR DETECTING PHYSICAL DEFECTS IN ARABICA COFFEE BEAN IMAGES)

Muh Aditya Dwijaya¹, Frans Richard Kodong²

^{1,2}Fakultas Teknik Industri Universitas Pembangunan Nasional Veteran Yogyakarta

email : 123210027@syudent.upnyk.ac.id, frans.ricard@upnyk.ac.id

Abstract

The increasing culture of coffee consumption has made coffee bean quality a key factor in the coffee industry. One important aspect is the physical condition of beans, which are still mostly sorted manually, especially in small to medium-scale industries. This manual process is prone to inconsistencies due to human fatigue and subjectivity. This study proposes an automated detection system for physical defects in Arabica coffee beans using the YOLOv8n algorithm, which is efficient for small-scale datasets. The dataset consists of green Arabica beans with seven physical defect classes. The development process includes data annotation, augmentation, model training, and implementation of a local web-based detection system. Model evaluation was carried out using precision, recall, and mean Average Precision (mAP). The best performance was achieved at epoch 30, with 83.2% precision, 89.4% recall, and mAP50/mAP50-95 of 97.1%. Further testing on multi-object images showed optimal detection at a distance of 10–15 cm. Evaluation of two key classes Insect Damage and Fungus Damage resulted in an average accuracy of 69.49%, precision of 89.02%, and recall of 75.93%. The proposed system demonstrates high potential for accurate and efficient defect detection in support of automated coffee bean sorting.

Keywords : YOLOv8n, object detection, Arabica coffee beans, physical defects, deep learning

PENDAHULUAN

Budaya konsumsi kopi mengalami peningkatan signifikan dalam beberapa tahun terakhir, ditandai dengan menjamurnya kedai kopi yang tidak hanya berfungsi sebagai tempat menikmati minuman, tetapi juga sebagai ruang sosial untuk berkumpul, berdiskusi, bekerja, hingga mengekspresikan diri di media sosial. Kopi telah berkembang menjadi simbol gaya hidup, khususnya di kalangan generasi milenial [1]. Perkembangan ini mempertegas posisi strategis kopi dalam sektor ekonomi, terutama bagi negara-negara penghasil utama seperti Indonesia. Menurut laporan [2], produksi kopi Indonesia pada tahun 2024/25 diperkirakan mencapai 10,9 juta kantong, menjadikannya produsen kopi terbesar keempat di dunia setelah Brasil, Vietnam, dan Kolombia.

Kualitas biji kopi sangat menentukan nilai jual dan cita rasa kopi. Salah satu indikator kualitas tersebut adalah kondisi fisik biji kopi. Berdasarkan standar dari [3], terdapat dua puluh jenis cacat fisik yang dapat ditemukan dalam biji kopi, seperti biji pecah, terpotong, berjamur, rusak akibat serangga, kulit tanduk tersisa, hingga biji keriput atau layu. Untuk menjamin kualitas, proses penyortiran biji kopi sangat penting. Namun, penyortiran manual yang masih banyak digunakan di industri kecil dan menengah seringkali tidak konsisten akibat kelelahan dan subjektivitas pekerja. Deteksi otomatis terhadap cacat fisik biji kopi dinilai mampu membantu proses sortir dan meningkatkan konsistensi mutu hasil produksi.

Berbagai penelitian sebelumnya telah berupaya mengembangkan sistem deteksi cacat pada biji kopi. [4] menggabungkan segmentasi citra menggunakan thresholding, ekstraksi fitur dengan GLCM, dan klasifikasi menggunakan algoritma C4.5 dengan teknik bagging, dan


berhasil mencapai akurasi 94%. Namun, metode tersebut masih tergolong sederhana dan kurang efektif dalam mendeteksi cacat kecil atau menghadapi noise. [5] menerapkan metode transfer learning dengan MobileNetV2 dan DenseNet201 yang disempurnakan melalui grid search, menghasilkan akurasi masing-masing sebesar 90% dan 93%. Meski demikian, beberapa kelas cacat masih sulit dikenali secara optimal. Sedangkan penelitian oleh [6] menggunakan YOLO berbasis aplikasi mobile dan mencapai akurasi 95,3% untuk biji hitam, namun masih rendah untuk biji berjamur atau memucat, yaitu 62,2%.

Pendekatan sebelumnya, baik konvensional, transfer learning, maupun versi YOLO yang lebih lama, masih memiliki keterbatasan dalam mendeteksi cacat berukuran kecil, samar, atau yang menyerupai biji normal. Hal ini menunjukkan perlunya pendekatan yang lebih adaptif dan akurat. Seiring kemajuan teknologi kecerdasan buatan, YOLOv8 hadir dengan arsitektur anchor-free yang menyederhanakan proses prediksi serta meningkatkan kecepatan dan akurasi. Arsitektur ini menggabungkan CSPNet, Feature Pyramid Network (FPN), dan Path Aggregation Network (PAN), sehingga mampu mendeteksi objek multiskala secara efisien [7]. Menurut [8], YOLOv8 mencapai AP_{small} sebesar 42,1% dalam dataset Pascal VOC, lebih tinggi dari YOLOv7, serta mampu melakukan inferensi hingga 128 FPS dengan model berukuran kecil sekitar 3,2 juta parameter.

Berdasarkan potensi tersebut, penelitian ini bertujuan untuk mengimplementasikan model YOLOv8 dalam mendeteksi cacat fisik pada biji kopi hijau Arabika dalam satu citra digital. Model ini diharapkan dapat memberikan kontribusi dalam pengembangan sistem penyortiran otomatis yang lebih andal dalam menjaga kualitas produk kopi.

METODOLOGI PENELITIAN

Penelitian ini menggunakan dataset sekunder dari Kaggle yang terdiri atas citra biji kopi Arabika dengan berbagai jenis cacat fisik. Data diproses melalui Roboflow untuk pembersihan, pelabelan objek, pembagian dataset, resize, dan augmentasi guna meningkatkan variasi data. Model YOLOv8n digunakan untuk pelatihan dan pengujian deteksi objek cacat. Evaluasi kinerja model dilakukan berdasarkan hasil prediksi terhadap data uji. Model terbaik diintegrasikan ke dalam antarmuka web lokal dan diuji lebih lanjut menggunakan citra multiobjek untuk menilai kemampuan deteksi pada skenario yang menyerupai kondisi nyata.



Gambar 2. 1 Alur metodologi penelitian

1. Pengumpulan Data

Penelitian ini menggunakan data sekunder yang diperoleh dari platform Kaggle (<https://www.kaggle.com/datasets/sujitraarw/coffee-green-bean-with-17-defects-original>). Dataset tersebut awalnya terdiri dari 17 kategori cacat fisik pada biji kopi hijau, namun dalam penelitian ini difokuskan pada 7 kategori cacat, yaitu *Broken*, *Cut*, *Fungus Damage*, *Insect Damage*, *Parchment*, *Shell*, dan *Withered*. Data yang digunakan berjumlah total 425 citra dan dimanfaatkan untuk proses pelatihan, validasi, dan pengujian model deteksi objek.

2. Pra-pemrosesan Data

Sebelum digunakan dalam proses pelatihan model, data melalui tahap pra-pemrosesan yang meliputi pembersihan, anotasi, penyesuaian ukuran, pembagian dataset, dan augmentasi.

Tahap pertama adalah cleaning data, yaitu menyaring citra yang tidak relevan, buram, atau tidak sesuai dengan tujuh kelas cacat fisik yang menjadi fokus penelitian, yaitu *Broken*, *Cut*, *Fungus Damage*, *Insect Damage*, *Parchment*, *Shell*, dan *Withered*. Setelah proses pembersihan, dataset tersisa sebanyak 421 citra.

Selanjutnya, dilakukan proses annotating menggunakan platform Roboflow. Setiap citra diberi label manual menggunakan bounding box sesuai dengan kelas cacat fisik yang diamati. Hasil anotasi disimpan dalam format yang sesuai dengan standar YOLOv8, yaitu file .txt yang berisi indeks kelas, posisi tengah objek (x, y), serta ukuran bounding box (width dan height).

Setelah anotasi, citra di-resize dari ukuran asli 500×500 piksel menjadi 640×640 piksel untuk menyesuaikan dengan format input YOLOv8. Penyesuaian ini dilakukan dengan metode interpolasi guna mempertahankan proporsi visual objek.

Dataset kemudian dibagi menjadi tiga bagian: 70% untuk pelatihan, 20% validasi, dan 10% pengujian. Hasil pembagian menghasilkan 295 data pelatihan, 84 data validasi, dan 42 data pengujian.

Tahap terakhir adalah augmentasi data yang hanya diterapkan pada data pelatihan. Teknik augmentasi yang digunakan antara lain flip horizontal, rotation $\pm 15^\circ$, random contrast $\pm 20\%$, dan sharpen dengan probabilitas 30%. Setelah augmentasi, jumlah data pelatihan bertambah menjadi 1.475 citra, sehingga total dataset akhir terdiri dari 1.475 citra pelatihan, 84 citra validasi, dan 42 citra pengujian.

3. Pelatihan Model

Setelah preprocessing, model YOLOv8n dilatih untuk mengenali dan mengklasifikasikan cacat fisik pada citra biji kopi. Proses pelatihan dilakukan menggunakan *Visual Studio Code* dengan bantuan *library Ultralytics* dan dataset yang telah diproses melalui *Roboflow*. Dataset diunduh dalam format yang kompatibel dengan arsitektur YOLOv8, kemudian dikonfigurasi dalam direktori proyek. Parameter pelatihan seperti jumlah epoch, ukuran gambar, dan batch size disesuaikan untuk mengoptimalkan performa model.

3.1 Konfigurasi

Dalam proses pelatihan model YOLOv8n, dataset yang telah diproses dan dianotasi diimpor dari platform *Roboflow*. Dataset ini dilengkapi dengan file konfigurasi yang memuat informasi penting. File tersebut mencantumkan nama kelas, jumlah kelas, versi dataset yang digunakan, serta jalur direktori (*path*) untuk data latih, validasi, dan uji.

3.2 Implementasi Model YOLOv8n

Proses pelatihan dilakukan dengan mengatur beberapa parameter utama guna memperoleh model yang optimal. Salah satu fokus utama adalah jumlah epoch, yang divariasikan menjadi 15, 30, dan 50 untuk mengamati pengaruhnya terhadap kinerja model. Variasi ini mempertimbangkan ukuran dataset yang terbatas, guna menghindari risiko overfitting maupun underfitting. *Overfitting* terjadi saat model terlalu menyesuaikan dengan data latih, sedangkan *underfitting* muncul ketika model belum cukup belajar dari data. Oleh

karena itu, perbandingan hasil pelatihan pada ketiga nilai epoch digunakan untuk menentukan konfigurasi terbaik. Parameter lainnya adalah ukuran batch sebesar 16 dan resolusi citra 640 piksel.

YOLOv8n merupakan model deteksi objek satu tahap (*one-stage detector*) yang menggabungkan efisiensi dan akurasi dalam arsitektur ringan. Arsitektur ini terdiri dari tiga komponen utama: *Backbone*, *Neck*, dan *Head*, dengan sejumlah lapisan penting seperti Conv2D, Batch Normalization, SiLU, MaxPool, dan Prediction Layer.

Pada tahap awal, citra yang telah dipreproses dimasukkan ke dalam layer Conv2D untuk mengekstraksi fitur menggunakan kernel 3×3 dan stride 2. Proses konvolusi ini menghasilkan representasi spasial dalam bentuk matriks yang selanjutnya dinormalisasi menggunakan Batch Normalization, yang mencakup perhitungan mini-batch mean, varians, normalisasi nilai, dan proses penskalaan.

Setelah itu, aktivasi dilakukan menggunakan fungsi SiLU (*Sigmoid Linear Unit*) untuk memperkenalkan non-linearitas pada hasil konvolusi. Lapisan MaxPool2D kemudian mengambil nilai maksimum dari hasil aktivasi dengan kernel 2×2 dan stride 1 guna mengurangi dimensi spasial dan mempertahankan fitur penting.

Selanjutnya, Upsample digunakan untuk memperbesar dimensi fitur, diikuti oleh operasi Concatenation guna menggabungkan feature map dari beberapa layer. Komponen Head pada YOLOv8n bertanggung jawab menghasilkan output akhir berupa bounding box, label kelas, serta confidence score menggunakan pendekatan anchor-free.

4. Evaluasi Model

Evaluasi dilakukan untuk menilai kinerja model YOLOv8n dalam mendeteksi cacat fisik pada citra biji kopi menggunakan tiga konfigurasi jumlah epoch, yaitu 15, 30, dan 50. Parameter evaluasi yang digunakan meliputi precision, recall, dan mean Average Precision (mAP). Pemilihan jumlah epoch yang berbeda bertujuan untuk mengetahui sejauh mana model dapat belajar dari data secara optimal tanpa mengalami overfitting maupun underfitting.

5. Pengembangan Sistem

Metodologi pengembangan sistem yang digunakan dalam penelitian ini adalah *Waterfall*, yang terdiri dari beberapa tahapan berurutan, yaitu analisis kebutuhan (*requirement analysis*), perancangan sistem (*system design*), implementasi (*implementation/coding*), pengujian (*testing*), dan pemeliharaan (*maintenance*). Pada tahap pengujian dilakukan menggunakan metode *black box testing*. Metode ini dipilih karena berfokus pada pengujian fungsionalitas sistem tanpa memerlukan pemahaman terhadap kode sumber atau struktur internal aplikasi.

6. Pengujian Model Sistem

Pengujian model dilakukan pada citra multiobjek untuk mensimulasikan kondisi penyortiran biji kopi di dunia nyata, di mana satu gambar memuat banyak biji kopi sekaligus, masing-masing berpotensi memiliki lebih dari satu jenis cacat. Gambar kolase digunakan sebagai media uji untuk mengamati kemampuan model dalam mendeteksi beberapa objek dalam satu frame.


Evaluasi difokuskan pada jumlah deteksi benar, deteksi salah, dan objek cacat yang tidak terdeteksi. Tujuannya adalah untuk mengukur kemampuan generalisasi model terhadap citra kompleks, serta mengidentifikasi potensi kesalahan seperti duplikasi deteksi atau kegagalan mengenali objek. Hasil dari pengujian ini menjadi validasi tambahan terhadap performa model dalam konteks operasional yang lebih mendekati penerapan di industri.

HASIL DAN PEMBAHASAN

Hasil dari penelitian ini akan dijelaskan pada bagian berikut. Penjelasan disusun berdasarkan tahapan yang telah dilakukan selama proses penelitian.

1. Pengumpulan Data

Data yang digunakan dalam penelitian ini merupakan data sekunder yang diperoleh dari platform Kaggle (<https://www.kaggle.com/datasets/sujitraarw/coffee-green-bean-with-17-defects-original>). Dari keseluruhan data, dipilih 7 kategori cacat fisik yang digunakan sebagai kelas dalam penelitian ini.



Gambar 3. 1 Hasil pengumpulan data

2. Pra-pemrosesan Data

Pengolahan dataset dimulai dengan proses cleaning untuk menghapus citra yang tidak relevan, buram, atau berkualitas rendah, sehingga tersisa 421 citra yang layak digunakan. Selanjutnya, dilakukan anotasi manual menggunakan bounding box di platform Roboflow untuk menandai area cacat fisik pada biji kopi dan memberi label kelas yang sesuai. Citra kemudian diubah ukurannya dari 500×500 piksel menjadi 640×640 piksel agar sesuai dengan format input YOLOv8. Setelah itu, data dibagi menjadi tiga subset, yaitu 70% untuk pelatihan, 20% validasi, dan 10% pengujian, menghasilkan masing-masing 295, 84, dan 42 citra. Terakhir, data latih diperluas melalui augmentasi menggunakan teknik flip horizontal, rotasi, penyesuaian kontras, dan sharpen, sehingga jumlah citra data latih meningkat menjadi 1.475 untuk mendukung generalisasi model yang lebih baik.

3. Pelatihan Model

Sebelum proses pelatihan dimulai, dilakukan konfigurasi awal terhadap model YOLOv8n dengan menyesuaikan file data.yaml. File ini berfungsi mendefinisikan informasi dasar tentang dataset yang digunakan, termasuk jalur direktori untuk data latih, validasi, dan uji, jumlah kelas objek yang akan dideteksi, serta daftar nama kelas target.



Gambar 3. 2 File konfigurasi

Setelah konfigurasi awal selesai, proses dilanjutkan dengan pelatihan model YOLOv8 menggunakan model pra-latih yolov8n.pt. Pelatihan mengacu pada informasi dalam file konfigurasi data.yaml, termasuk lokasi dataset dan daftar kelas target. Model dilatih dengan tiga variasi epoch, yaitu 15, 30, dan 50, untuk membandingkan performa deteksi pada setiap tingkat pelatihan.

Hasil pelatihan menunjukkan penurunan train loss dan validation loss yang konsisten hingga epoch ke-30, menandakan proses pembelajaran berjalan efektif. Setelah itu, penurunan mulai melambat pada epoch ke-50, mengindikasikan model telah mendekati konvergensi. Fluktuasi ringan pada validation loss di akhir pelatihan menunjukkan potensi overfitting. Di sisi lain, precision, recall, dan mAP meningkat signifikan hingga epoch ke-30, kemudian cenderung stabil. Hal ini menunjukkan bahwa epoch ke-30 merupakan titik pelatihan optimal, dengan keseimbangan antara akurasi tinggi dan kemampuan generalisasi yang baik.

4. Evaluasi Model

Setelah pelatihan dengan tiga konfigurasi epoch (15, 30, dan 50), evaluasi dilakukan menggunakan metrik precision, recall, mAP50, dan mAP50-95 terhadap data uji.

Tabel 3. 1 Hasil evaluasi data test

No	Epoch	Presicion	Recall	mAP50	mAP50-95
1	15	0.902	0.857	0.947	0.944
2	30	0.832	0.894	0.971	0.971
3	50	0.917	0.893	0.945	0.943

Hasil menunjukkan bahwa masing-masing model memiliki keunggulan tersendiri. Model pada epoch ke-15 menunjukkan performa yang cukup seimbang, dengan nilai mAP50 sebesar 0.947. Epoch ke-30 menghasilkan nilai mAP tertinggi (0.971), yang menunjukkan kemampuan deteksi paling akurat secara umum, meskipun precision sedikit menurun. Sementara itu, model pada epoch ke-50 mencatat precision tertinggi (0.917), namun disertai sedikit penurunan mAP dan indikasi awal overfitting. Berdasarkan evaluasi tersebut, model pada epoch ke-30 dipilih sebagai model terbaik karena menawarkan akurasi deteksi tertinggi dan keseimbangan performa yang baik untuk tahap implementasi sistem.

5. Pengembangan Sistem

Sistem deteksi cacat fisik pada citra biji kopi Arabika diimplementasikan dalam bentuk aplikasi web lokal dengan arsitektur client-server. Sistem terdiri atas antarmuka pengguna (frontend) yang dikembangkan menggunakan PHP, HTML, dan JavaScript, serta backend berbasis Python menggunakan framework Flask. Antarmuka pengguna menyediakan fitur unggah gambar, yang memungkinkan pengguna memilih file citra dari perangkat lokal. Saat tombol “Deteksi Gambar” ditekan, JavaScript mencegat pengiriman form default, lalu mengirimkan gambar ke backend secara asinkron melalui metode fetch() menggunakan HTTP POST.

Di sisi backend, API Flask menerima gambar pada endpoint /deteksi, menyimpannya sementara dengan tempfile, lalu membaca citra menggunakan OpenCV. Gambar diproses oleh model YOLOv8n terlatih melalui fungsi model.predict(), yang menghasilkan bounding box, label kelas, confidence score, dan mencatat waktu inferensi menggunakan time.time(). Proses ini mengacu pada model terbaik hasil pelatihan sebelumnya dengan konfigurasi input 640 piksel dan threshold 0.25. Hasil deteksi kemudian divisualisasikan menggunakan OpenCV: cv2.rectangle menggambar bounding box, dan cv2.putText menambahkan label serta confidence di atas citra. Untuk membedakan antar kelas, warna anotasi dihasilkan secara acak dengan NumPy (np.random.randint).


Setelah proses deteksi dan visualisasi selesai, hasil dikodekan dalam format base64 dan dikemas dalam format JSON, termasuk daftar kelas objek terdeteksi, nilai confidence, dan waktu inferensi. Data ini dikembalikan ke antarmuka pengguna, yang kemudian ditampilkan secara langsung tanpa memuat ulang halaman. Hasil deteksi divisualisasikan dalam elemen , sementara informasi objek ditampilkan dalam bentuk daftar. Dengan rancangan ini, sistem mampu melakukan deteksi secara real-time dan memberikan pengalaman pengguna yang interaktif dan efisien, serta merepresentasikan kondisi penyortiran biji kopi secara simultan seperti di industri.

Pengujian sistem dilakukan menggunakan metode *black box testing*, sesuai dengan skenario yang telah dirancang sebelumnya.

Tabel 3. 2 Hasil testing sistem

No	Test Case	Hasil
1.	Pengguna dapat membuka sistem	Berhasil
2.	Pengguna dapat menginput gambar	Berhasil
3.	Sistem mampu melakukan deteksi dan klasifikasi objek berdasarkan tujuh kelas yang telah ditentukan dalam penelitian ini.	Berhasil
4.	Sistem dapat menampilkan hasil deteksi berupa objek yang telah dikenali beserta klasifikasinya.	Berhasil

dibawah menunjukkan tampilan sistem deteksi yang telah dikembangkan. Pada halaman ini, terdapat fitur utama berupa unggah gambar untuk proses deteksi, serta penyajian hasil deteksi yang mencakup gambar hasil anotasi dan detail informasi objek yang terdeteksi.




Gambar 3. 3 Tampilan sistem deteksi

6. Pengujian Model Sistem

Pengujian model pada sistem dilakukan berdasarkan skenario yang telah dirancang sebelumnya, dengan tujuan untuk mensimulasikan kondisi nyata penyortiran biji kopi secara multi-objek.

Tabel 3. 3 Hasil pengujian model

No	Gambar Hasil Deteksi	Jarak	Keterangan
1.		10 cm	Sistem mampu mendeteksi objek dengan benar yaitu cacat insect damage Total objek dalam gambar adalah 6 objek dan yang berhasil dan benar dideteksi ada 4 objek
2.		15 cm	Sistem mampu mendeteksi objek dengan benar yaitu cacat insect damage Total objek dalam gambar adalah 6 objek dan yang berhasil dan benar dideteksi ada 3 objek
3.		30 cm	Sistem mampu mendeteksi objek dengan benar yaitu cacat insect damage Total objek dalam gambar adalah 6 objek dan tidak ada objek terdeteksi
4.		10 cm	Sistem mampu mendeteksi objek dengan benar yaitu cacat fungus damage Total objek dalam gambar adalah 5 objek dan yang berhasil dan benar dideteksi ada 5 objek

Tabel 3. 3 Lanjutan hasil pengujian model

No	Gambar Hasil Deteksi	Jarak	Keterangan
5.		15 cm	Sistem mampu mendeteksi objek dengan benar yaitu cacat fungus damage Total objek dalam gambar adalah 5 objek dan yang berhasil dan benar dideteksi ada 5 objek
6.		30 cm	Sistem mampu mendeteksi objek dengan benar yaitu cacat fungus damage Total objek dalam gambar adalah 5 objek dan yang berhasil dan tidak ada objek terdeteksi

Pengujian sistem dilakukan menggunakan citra multi-objek yang berisi lebih dari satu biji kopi cacat dalam satu gambar, guna mensimulasikan kondisi nyata penyortiran di industri. Hasil pengujian menunjukkan bahwa performa deteksi model dipengaruhi oleh jarak pengambilan gambar. Pada jarak 10 cm, sistem mampu mendeteksi sebagian besar objek dengan akurasi tinggi, seperti mendeteksi 4 dari 6 objek insect damage dan seluruh 5 objek fungus damage secara tepat. Namun, pada jarak 15 cm, akurasi menurun dengan hanya 3 dari 6 objek insect damage terdeteksi, meskipun deteksi fungus damage tetap akurat. Penurunan performa signifikan terjadi pada jarak 30 cm, di mana tidak satu pun dari total 11 objek cacat berhasil terdeteksi. Temuan ini menunjukkan bahwa kejelasan visual fitur cacat sangat memengaruhi kinerja deteksi, dan jarak pengambilan gambar menjadi faktor penting yang perlu diperhatikan dalam implementasi sistem deteksi otomatis di lingkungan nyata.

KESIMPULAN DAN SARAN

Penelitian ini bertujuan untuk mengimplementasikan metode You Only Look Once versi 8, khususnya model YOLOv8n, dalam mendeteksi tujuh jenis cacat fisik pada citra biji kopi Arabika, yaitu broken, cut, fungus damage, insect damage, parchment, shell, dan withered. Model dilatih menggunakan tiga konfigurasi epoch, dan hasil terbaik diperoleh pada epoch ke-30 dengan nilai precision sebesar 0,832, recall sebesar 0,894, mAP50 sebesar 0,971, dan mAP50-95 sebesar 0,710. Model ini menunjukkan keseimbangan terbaik antara akurasi deteksi dan kemampuan generalisasi dibandingkan dengan model pada epoch lainnya.

Sistem kemudian diimplementasikan dalam bentuk aplikasi web lokal, dengan frontend berbasis PHP dan backend menggunakan Python Flask. Sistem ini mampu menerima input citra dari pengguna dan menampilkan hasil deteksi berupa visualisasi bounding box, label objek, serta tingkat kepercayaan secara langsung tanpa perlu memuat ulang halaman.

Pengujian dilakukan dengan menggunakan citra multi-objek pada tiga jarak berbeda, yaitu 10 cm, 15 cm, dan 30 cm, untuk mensimulasikan kondisi nyata penyortiran di industri. Hasil menunjukkan bahwa model mampu mendeteksi sebagian besar objek cacat pada jarak 10–15 cm, terutama pada kelas insect damage dan fungus damage. Namun, akurasi menurun secara

drastis pada jarak 30 cm, di mana tidak ada objek cacat yang berhasil terdeteksi. Penurunan ini disebabkan oleh semakin kecilnya ukuran visual fitur cacat, sehingga sulit dikenali oleh model. Temuan ini menunjukkan bahwa pendekatan berbasis YOLOv8n memiliki potensi untuk digunakan dalam sistem penyortiran otomatis, meskipun peningkatan terhadap deteksi objek kecil masih perlu dikembangkan.

Untuk pengembangan selanjutnya, dataset perlu ditingkatkan dari segi jumlah, kualitas, dan variasi kondisi agar model lebih akurat dan tangguh. Sistem juga dapat dikembangkan menjadi aplikasi real-time yang terhubung dengan kamera untuk mendukung proses penyortiran otomatis. Selain itu, pelatihan model yang lebih adaptif perlu dikaji agar sistem mampu mengenali objek cacat yang saling tumpang tindih, seperti yang umum terjadi dalam proses industri.

REFERENSI

- [1] Petty Arisanti, "Tren Gaya Hidup Milenial, Identitas Sosial dan Desain Coffe Shop Petty Arisanti," vol. 18, no. 4, 2021, [Online]. Available: <http://journal.undiknas.ac.id/index.php/magister-manajemen/579>
- [2] USDA, "Indonesia Coffee Annual Report 2024/25," 2024. [Online]. Available: <https://www.fas.usda.gov/data/indonesia-coffee-annual-8>
- [3] Badan Standardisasi Nasional, "SNI 01-2907-2008: Biji Kopi," Jakarta, 2008. Accessed: May 30, 2025. [Online]. Available: https://www.cctcid.com/wp-content/uploads/2018/08/SNI_2907-2008_Biji_Kopi-1.pdf
- [4] A. Rahmawati, Y. Rianto, and D. Riana, "Deteksi defect coffee pada citra tunggal green beans menggunakan metode ensemble decision tree," *Techno.COM*, vol. 20, no. 2, pp. 198–209, 2021, [Online]. Available: <https://ejurnal.nusamandiri.ac.id/index.php/techno/article/view/2821>
- [5] A. Michael and J. Rusman, "Klasifikasi Cacat Biji Kopi Menggunakan Metode Transfer Learning dengan Hyperparameter Tuning Gridsearch," *Jurnal Teknologi dan Manajemen Informatika (JTMI)*, vol. 9, no. 1, pp. 37–45, 2023, [Online]. Available: <https://jurnal.unmer.ac.id/index.php/jtmi/article/view/6908>
- [6] E. D. Nugroho *et al.*, "Development of YOLO-based mobile application for detection of defect types in robusta coffee beans," *Journal of Applied Informatics and Computing*, vol. 9, no. 1, pp. 153–160, 2025, [Online]. Available: <http://jurnal.polibatam.ac.id/index.php/JAIC/article/view/1037>
- [7] Ultralytics, "YOLOv8 Documentation," Ultralytics. Accessed: May 30, 2025. [Online]. Available: <https://docs.ultralytics.com/models/yolov8/>
- [8] L. Gao and J. Zhao, "YOLOv8 Algorithm Improvement and Its Application in Small Target Detection," *Traitement du Signal*, vol. 42, no. 2, pp. 985–994, Apr. 2025, doi: 10.18280/ts.420232.